Skriti markovski modeli v časovnih vrstah

Skriti markovsk model








I wife plan for program the forest for any of the project for an all a field that the forest form and forest form and forest form the forest f





## Skriti markovski modeli v časovnih vrstah

Fakulteta za matematiko in fiziko, Univerza v Ljubljani


10. december 2018

Martin Praček Mentor: izr. prof. dr. Damjan Škulj

## Markovski model

Skriti markovski modeli v časovnih vrstah

- Markovska lastnost je lastnost slučajnega procesa, da je njegova vrednost v času t odvisna le od njegove vrednosti v času t – 1.
- Ločimo v celoti opazovan in delno opazovan ter
- Avtonomen in kotroliran sistem.



#### Delitev markovskih modelov

Skriti markovski modeli v časovnih vrstah


Skriti markovsk model

Avtonomen V celoti opazovan Le delno opazovan Avtonomen Markovska veriga Skriti markovski model Kontorliran Markovski proces odločanja Delno opazovalen proces odločanja

Skriti markovski modeli v časovnih vrstah

Skriti markovski model Skriti markovski model je statistični markovski model, kjer predpostavljamo, da je modelirani sistem markovski proces z skritimi stanji.


Gre torej za tip modela, kjer lahko razberemo rezultat, ne moremo pa ugotoviti, kakšna je bila funkcija, ki nam ga je dala.



## Zahteve

Skriti markovski modeli v časovnih vrstah

- Markovska lastnost
- Enaki razdeljeni časi signalov
- Sistem ima *N* stanj, vsako določa slučajna spremenjivka *S*



- Slučajnih spremenljivk v nobenem času ne poznamo, poznamo pa slučajni proces Q, ki predstavlja signale
- Porazdelitveno funkcijo vsakega stanja i označimo z  $b_i(x)$
- Vektor začetnih stanj je П
- Prehodna matrika A, ki je neodvisna od časa

# Porazdelitvena funkcija

Skriti markovski modeli v časovnih vrstah


- Gaussova mešanica
- $\bullet b_i = \sum_{j=1}^M c_{ij} N(x; \mu_j, \sigma_j^2)$
- Število mešanic M
- $\blacksquare$  Matrika  $\Gamma$ ,  $\mu_{ij}$  predstavlja pričakovano vrednost mešanice j v stanju i
- Matrika  $\Sigma$ , kjer  $\sigma_{ij}$  predstavlja varianco mešanice j v stanju i
- Matrika *C*, koeficienti *c<sub>ij</sub>* iz Gaussove mešanice

## Osnovanje modela

Skriti markovski modeli v časovnih vrstah

Skriti markovski model Da bomo lahko delali z našim modelom, moramo najprej izvesti t.i. trening modela.

- šop *k*-povprečij
- Akaikov informacijski kriterij



Z  $\lambda$  označimo vse ostale parametre  $\lambda=(\Pi,A,C,\Gamma,\Sigma)$ . Za učinkovit izračun le teh delamo naprej-nazaj.


$$\alpha_1(i) = \pi_i b_i(O_1) = \pi_i b_i = \sum_{k=1}^M c_{ik}$$

$$\downarrow \downarrow$$

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$

## Trening modela

Skriti markovski modeli v časovnih vrstah



# Trening modela


Skriti markovski modeli v časovnih vrstah

Skriti markovski model Da bomo lahko  $P(O|\lambda)$  maksimizirali, potrebujemo začetne ocene parametrov. Za to ne poznamo analitičnega postopka, lahko pa lokalno maksimiziramo, z naprimer, Baum-Welchovim algoritmom. Pri tem nas ne skrbijo ocene za A ter  $\Pi$ , kjer moramo paziti le na neničelnost le teh. Več problemov nam povzročajo C,  $\Sigma$  in  $\Gamma$ .

# C, $\Sigma$ in $\Gamma$

Skriti markovski modeli v časovnih vrstah

Skriti markovski model Za dobro začetno oceno si lahko pomagamo z šopom k-povprečij. Za C to pomeni, da bo element  $c_{ij}=1/k$  za vsak par ij, kjer je k število šopov povprečij. Pričakovane vrednosti in variance nato pridobimo iz vrednosti teh šopov povprečij.




# Lokalno maksimiziranje

Skriti markovski modeli v časovnih vrstah

Skriti markovski model Za potrebe lokalne maksimizacije določimo dodatne funkcije:

$$\xi_t(i,j) = \frac{\alpha_t(i)a_{ij}b_j(O_t)\beta_{t+1}(j)}{P(O|\lambda)}$$
$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O|\lambda)}$$
$$\gamma_t(j,k) = \gamma_t(j)\frac{c_{jk}N(x;\mu_{jk},\sigma_{jk}^2)}{\sum_{m=1}^{M}c_{jm}N(x;\mu_{jm},\sigma_{jm}^2)}$$



# Lokalno maksimiziranje

Skriti markovski modeli v časovnih vrstah

Skriti markovski model Prek dodatnih funkcij definiramo iteracijske postopke za naše spremenljivke:

$$\overline{\Pi_{i}} = \gamma_{1}(i)$$

$$\overline{a_{ij}} = \frac{\sum_{t=1}^{T-1} \xi_{t}}{\sum_{t=1}^{T-1} \gamma_{t}(i)}$$

$$\overline{c_{jk}} = \frac{\sum_{t=1}^{T} \gamma_{t}(j, k)}{\sum_{t=1}^{T} \sum_{m=1}^{M} \gamma_{t}(j, m)}$$

$$\overline{\mu_{jk}} = \frac{\sum_{t=1}^{T} \gamma_{t}(j, k) O_{t}}{\sum_{t=1}^{T} \gamma_{t}(j, k)}$$

# Začetno stanje in Viterbijev algoritem

Skriti markovski modeli v časovnih vrstah

Skriti markovski model

Za delo s tem algoritmom moramo definirati  $\delta_t(i)$ , ki za vsako stanje i vrne največjo verjetnost vzdolž poti v času t. Prek  $\delta_t(i)$  nato induktivno izvedemo algoritem.

Viterbijev algoritem nam vrne p\*, ki je največja verjetnost in  $q_T*$ , ki nam pove stanje v času T, ki nam to verjetnost vrne.

# Uporaba

Skriti markovski modeli v časovnih vrstah

Skriti markovski model

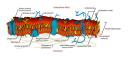






I mily dot on fry to cast awayd it projectly down that jet that the logisty have I have been the first that the logisty have I have been the first that the logisty for accounting any quant starts a fightly only all the logisty for the logist that the logisty was accounted in the property and the second on the logisty was a found to property and for place a way of the promise was going for place a counter of the promise was going for place a Charles C. Whiches





V dolgi predstavitvi se bom bolj posvetil sami finančni analizi, ki sem jo tokrat zaenkrat pustil pri miru. V prihodnje bom tudi sam poizkusil določiti skriti markovski model na svojem setu podatkov.